

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút):
<https://youtu.be/dVivaO0A1co>
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/taingph2502/CS2205.CH203/blob/Main/T%C3%A0i%20Nguy%E1%BB%85n%20Ph%C3%BA%20-%20CS2205.JAN2026.DeCuong.FinalReport.Template.Slide.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Nguyễn Phú Tài
- MSSV: 250101103



- Lớp: CS2205.CH203
- Tự đánh giá (điểm tổng kết môn): 9.5/10
- Số buổi vắng: 2
- Số câu hỏi QT cá nhân: 3
- Link Github:
<https://github.com/taingph2502/CS2205.CH203>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

MÔ HÌNH THẾ GIỚI CÓ NỀN TẢNG VẬT LÝ CHO THAO TÁC GIA DỤNG
DÀI HẠN

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

PHYSICALLY GROUNDED WORLD MODEL FOR LONG-HORIZON
HOUSEHOLD MANIPULATION

TÓM TẮT *(Tối đa 400 từ)*

Đề tài hướng đến xây dựng một mô hình thế giới (world model) giúp robot gia dụng không chỉ nhận diện môi trường, mà còn dự đoán được hệ quả vật lý của hành động trong các nhiệm vụ thao tác dài hạn. Trong môi trường gia đình, một yêu cầu như “dọn bàn ăn rồi cất ly vào tủ” không phải là một hành động đơn lẻ, mà là chuỗi nhiều bước phụ thuộc lẫn nhau: nhận diện vật thể, ước lượng độ dễ vỡ, tránh va chạm, mở tủ, đặt vật đúng vị trí, và sửa kế hoạch khi trạng thái môi trường thay đổi. Các mô hình robot hiện nay đã tiến bộ mạnh nhờ Vision-Language-Action models (VLA) và imitation learning, nhưng vẫn thường gặp khó khăn khi phải duy trì tính nhất quán vật lý qua nhiều bước, đặc biệt với tiếp xúc, ma sát, vật thể bị che khuất, khớp bản lề, vật dễ vỡ hoặc trạng thái không thể đảo ngược.

Nghiên cứu này tập trung vào câu hỏi: làm thế nào để robot hình thành một biểu diễn dự đoán được “điều gì sẽ xảy ra nếu làm hành động này” trong bối cảnh gia dụng dài hạn. Đề tài dự kiến kết hợp biểu diễn cảnh theo đối tượng, suy luận ngữ nghĩa từ ngôn ngữ tự nhiên, và mô hình động lực học có ràng buộc vật lý để hỗ trợ lập kế hoạch, kiểm tra khả thi và tái lập kế hoạch trong vòng kín. Kết quả kỳ vọng là một khung nghiên cứu có thể đánh giá được khả năng dự đoán, khả năng hoàn thành nhiệm vụ, mức độ an toàn vật lý và tính tổng quát trên các nhiệm vụ như dọn bàn, chuẩn bị đồ uống, cất đồ vào ngăn kéo hoặc sắp xếp vật dụng nhà bếp.

GIỚI THIỆU *(Tối đa 1 trang A4)*

Robot gia dụng là một mục tiêu trung tâm của Embodied Intelligence, nơi trí tuệ nhân tạo phải hiểu thế giới qua cảm biến và hành động trong không gian vật lý. Khác với chatbot

chỉ xử lý văn bản, robot phải đối mặt với các trường hợp thực tế như: ly có thể vỡ, ngăn kéo có thể kẹt, vật bị che khuất, lực nắm không ổn định và chuỗi hành động dài có thể thất bại ở bất kỳ bước nào. Các hệ như SayCan, PaLM-E, RT-1, RT-2 và Octo cho thấy robot có thể kết hợp ngôn ngữ, thị giác và hành động ở quy mô ngày càng lớn; các benchmark như CALVIN, BEHAVIOR và RoboCasa cũng đưa nghiên cứu đến gần hơn với nhiệm vụ gia dụng thực tế. Tuy nhiên, thành công trong thao tác gia dụng dài hạn vẫn đòi hỏi năng lực dự đoán hệ quả hành động, chứ không chỉ chọn hành động kế tiếp từ quan sát hiện tại.

Bài toán sẽ nhận đầu vào gồm: câu lệnh bằng ngôn ngữ tự nhiên, ví dụ “hãy dọn bàn và cất chiếc cốc gốm vào tủ”; dữ liệu RGB-D từ camera; trạng thái robot như vị trí tay gắp, lực nắm, lịch sử hành động; và trạng thái cảnh như “cốc đang ở mép bàn”, “tủ đang đóng”, “đĩa nằm dưới khăn”. Từ đó, đầu ra không chỉ là lệnh điều khiển robot, mà còn gồm kế hoạch con, dự đoán trạng thái tương lai, đánh giá rủi ro và quyết định tái lập kế hoạch. Ví dụ, robot cần suy luận rằng nên nhấc cốc theo phương thẳng đứng trước khi quay tay, không nên kéo khăn nếu trên khăn có ly, và phải mở cửa tủ trước khi đưa vật vào.

Hiện nay, khoảng trống nghiên cứu chính là sự thiếu liên kết giữa ba năng lực: hiểu ngữ nghĩa ở mức cao, dự đoán vật lý ở mức đủ tin cậy, và lập kế hoạch dài hạn trong vòng kín. VLA mạnh về ánh xạ ngôn ngữ-thị giác-hành động nhưng thường thiếu mô hình dự đoán vật lý tường minh. Video world models có thể tạo tương lai trông hợp lý nhưng chưa chắc bảo toàn tiếp xúc, vật thể, lực và tính khả thi của hành động. Các mô hình physics-informed như PIN-WM hoặc object-centric như FOCUS rất hứa hẹn, nhưng thường tập trung vào thao tác ngắn hoặc phạm vi vật lý hẹp. Vì vậy, đề tài chọn hướng xây dựng world model có nền tảng vật lý để liên kết ý nghĩa ngữ nghĩa với các hành vi có thể thực hiện được về mặt vật lý trong nhiệm vụ gia dụng dài hạn.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

1. Xây dựng biểu diễn cảnh gia dụng theo đối tượng và thuộc tính vật lý

Đề tài sẽ mô hình hóa cảnh thành các đối tượng, quan hệ và thuộc tính như vị trí 3D, trạng thái mở/đóng, khả năng chứa, độ dễ vỡ, vật liệu và khả năng sử dụng. Ví dụ, “cốc gốm trên bàn gần mép” khác “hộp nhựa trong ngăn kéo” vì rủi ro và thao tác phù hợp khác nhau.

2. Học mô hình thế giới dự đoán hệ quả hành động có ràng buộc vật lý


Mô hình sẽ dự đoán trạng thái tương lai sau chuỗi hành động như nắm, kéo,

đặt, đẩy, mở, đóng. Đồng thời ước lượng bất định và phát hiện vi phạm vật lý như xuyên vật thể, rơi vỡ, mất tiếp xúc hoặc đặt sai mặt phẳng.

3. Đánh giá mô hình trong lập kế hoạch thao tác dài hạn

Đề tài sẽ kiểm chứng trên các nhiệm vụ nhiều bước, ví dụ “chuẩn bị một tách trà”, “dọn bàn ăn”, “cất vật dụng vào đúng ngăn”. Kết quả được đo bằng tỷ lệ hoàn thành nhiệm vụ, số bước tái lập kế hoạch, lỗi vật lý, mức độ tổng quát sang vật thể/cảnh mới và hiệu quả so với baseline không có world model vật lý.

NỘI DUNG VÀ PHƯƠNG PHÁP



1. Câu hỏi nghiên cứu

- Biểu diễn object-centric có giúp giảm lỗi tích lũy trong nhiệm vụ dài hạn so với biểu diễn video/latent toàn cục không?
- Các ràng buộc vật lý như tiếp xúc, hỗ trợ, va chạm và trạng thái khớp có cải thiện lập kế hoạch không?
- Ước lượng bất định của world model có giúp robot biết khi nào cần quan sát lại hoặc tái lập kế hoạch không?

2. Áp dụng kỹ thuật Computational Thinking

Đề tài phân rã bài toán thành nhận thức cảnh, dự đoán động lực học, lập kế hoạch và điều khiển kỹ năng. Phần trừu tượng hóa biến ảnh thô thành đồ thị cảnh 3D gồm đối tượng-quan hệ-thuộc tính. Phần nhận dạng mẫu học các quy luật lặp lại như vật dễ vỡ cần lực nắm thấp, vật nằm trong ngăn kéo chỉ lấy được sau khi mở ngăn. Phần thiết kế thuật toán dùng rollout dự đoán, tìm kiếm ứng viên hành động và điều

khiến theo hướng receding-horizon: làm vài bước, quan sát lại, rồi cập nhật kế hoạch.

3. Về dữ liệu

Tận dụng benchmark và dữ liệu sẵn có: CALVIN cho chuỗi thao tác ngôn ngữ dài, BEHAVIOR cho hoạt động gia dụng, RoboCasa cho bối cảnh bếp đa dạng, RLBench/ManiSkill2 cho thao tác có mô phỏng vật lý, và Open X-Embodiment/Octo cho tiền huấn luyện chính sách robot. Một tập nhiệm vụ bổ sung có thể được thiết kế theo ba nhóm: sắp xếp, chuẩn bị đồ uống, và cất/lấy đồ trong tủ-ngăn kéo. Ví dụ nhiệm vụ “dọn bàn” gồm phát hiện vật, gom khăn, nhắc cốc, tránh làm rơi đĩa, mở tủ, đặt cốc đúng kệ.

4. Phương pháp kỹ thuật

Gồm bốn mô-đun. Thứ nhất, mô-đun perception dùng RGB-D, segmentation và VLM để tạo đồ thị cảnh object-centric: mỗi node là vật thể, mỗi edge là quan hệ như “nằm trên”, “bên trong”, “bị chặn”, “gắn với”, ... Thứ hai, mô-đun world model học dự đoán trạng thái tương lai ở hai mức: trạng thái có cấu trúc và biểu diễn latent cho phần khó quan sát. Mô hình nên là hybrid: neural dynamics để học từ dữ liệu, với tiền đề vật lý để giữ ràng buộc va chạm, hỗ trợ, trọng lực và khớp bản lề. Thứ ba, planner nhận sub-goal từ ngôn ngữ, sinh vài phương án hành động, dùng world model để mô phỏng nhanh và chọn phương án có xác suất thành công cao, rủi ro thấp. Thứ tư, skill policy có thể fine-tune từ Diffusion Policy hoặc Octo để thực thi hành động ở mức điều khiển liên tục.

5. Đánh giá

So sánh với bốn baseline: policy phản xạ không có world model, planner kiểu SayCan chỉ dùng khả năng sử dụng, world model không ràng buộc vật lý, và mô phỏng vật lý thuần. Độ đo gồm tỉ lệ hoàn thành task, độ hoàn thiện mục tiêu con, tỷ lệ vi phạm vật lý, dự đoán lỗi theo đối tượng, số lần tái lập kế hoạch, độ hiệu chuẩn bất định và khả năng tổng quát sang vật thể/cảnh mới. Ví dụ, với nhiệm vụ “cất cốc vào tủ”, một lỗi vật lý được tính khi dự đoán cho phép tay robot xuyên qua cửa tủ, đặt cốc lơ lửng, hoặc tiếp tục kế hoạch dù cốc đã trượt khỏi tay gấp.

KẾT QUẢ MONG ĐỢI

Kết quả mong đợi là một prototype nghiên cứu có thể chạy trong mô phỏng gia dụng và, nếu điều kiện thiết bị cho phép, thử nghiệm nhỏ trên tay máy thật. Prototype cho phép

nhập lệnh tự nhiên, quan sát cảnh RGB-D, sinh kế hoạch nhiều bước, dự đoán trạng thái tương lai và tự tái lập kế hoạch khi dự đoán sai. Sản phẩm nghiên cứu gồm: mô hình biểu diễn cảnh object-centric, world model có ràng buộc vật lý, bộ nhiệm vụ đánh giá dài hạn, báo cáo so sánh với baseline và phân tích lỗi.

Về mặt học thuật, đề tài kỳ vọng làm rõ khi nào world model thật sự giúp thao tác robot, thay vì chỉ tạo dự đoán đẹp về mặt hình ảnh. Về mặt ứng dụng, hệ thống có thể minh họa các tác vụ gần đời sống như dọn bàn, sắp xếp bếp, lấy-cắt vật dụng trong ngăn kéo. Kết quả thành công không nhất thiết là robot “làm mọi việc trong nhà”, mà là chứng minh một hướng khả thi: robot biết dự đoán hệ quả vật lý trước khi hành động, nhận ra kế hoạch rủi ro, và điều chỉnh hành vi trong các chuỗi thao tác dài.

TÀI LIỆU THAM KHẢO (*Định dạng DBLP*)

[1] David Ha, Jürgen Schmidhuber:

Recurrent World Models Facilitate Policy Evolution.

NeurIPS 2018: 2455-2467.

[2] Danijar Hafner, Timothy P. Lillicrap, Ian Fischer, Ruben Villegas, David Ha, Honglak Lee, James Davidson:

Learning Latent Dynamics for Planning from Pixels.

ICML 2019: 2555-2565.

[3] Michael Ahn et al.:

Do As I Can, Not As I Say: Grounding Language in Robotic Affordances.

CoRR abs/2204.01691, 2022.

[4] Oier Mees, Lukás Hermann, Erick Rosete-Beas, Wolfram Burgard:

CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks.

IEEE Robotics Autom. Lett. 7(3): 7327-7334, 2022.

[5] Sanjana Srivastava et al.:

BEHAVIOR: Benchmark for Everyday Household Activities in Virtual, Interactive, and Ecological Environments.

CoRL 2021: 477-490.

[6] Danny Driess et al.:

PaLM-E: An Embodied Multimodal Language Model.

ICML 2023: 8469-8488.

[7] Anthony Brohan et al.:

RT-1: Robotics Transformer for Real-World Control at Scale.

Robotics: Science and Systems, 2023.

[8] Brianna Zitkovich et al.:

RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control.

CoRL 2023, PMLR 229: 2165-2183.

[9] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, Shuran Song:

Diffusion Policy: Visuomotor Policy Learning via Action Diffusion.

Robotics: Science and Systems, 2023.

[10] Jensen Gao, Bidipta Sarkar, Fei Xia, Ted Xiao, Jiajun Wu, Brian Ichter, Anirudha Majumdar, Dorsa Sadigh:

Physically Grounded Vision-Language Models for Robotic Manipulation.

ICRA 2024.

[11] Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay Mandlekar, Yuke Zhu:

RoboCasa: Large-Scale Simulation of Everyday Tasks for Generalist Robots.

CoRR abs/2406.02523, 2024.

[12] Octo Model Team, Dibya Ghosh et al.:

Octo: An Open-Source Generalist Robot Policy.

Robotics: Science and Systems, 2024.

[13] Stefano Ferraro, Pietro Mazzaglia, Tim Verbelen, Bart Dhoedt:

FOCUS: Object-Centric World Models for Robotic Manipulation.

Frontiers in Neurorobotics, 2025.

[14] Siyuan Zhou, Yilun Du, Jiaben Chen, Yandong Li, Dit-Yan Yeung, Chuang Gan:

RoboDreamer: Learning Compositional World Models for Robot Imagination.

ICML 2024.

[15] Wenxuan Li, Hang Zhao, Zhiyuan Yu, Yu Du, Qin Zou, Ruizhen Hu, Kai Xu:

PIN-WM: Learning Physics-INformed World Models for Non-Prehensile Manipulation.

Robotics: Science and Systems, 2025.

